Simulação de Aprendizado Federado: Resultados Experimentais

Júlio

4 de março de 2026

1 Problema Utilizado

Os experimentos foram conduzidos sobre o conjunto de dados **CIFAR-10**, composto por 60.000 imagens coloridas 32×32 pixels distribuídas em 10 classes (*airplane, automobile, bird, cat, deer, dog, frog, horse, ship, truck*), com 50.000 exemplos de treino e 10.000 de teste. Os valores de pixel foram normalizados para $[0, 1]$.

A distribuição dos dados entre clientes foi avaliada em dois cenários: **IID** e **Não-IID**, descritos a seguir.

Cenário IID. As proporções de dados de cada cliente são amostradas de uma distribuição de Dirichlet $\mathrm{Dir}(\mathbf{1}_N)$, garantindo que cada cliente receba uma fração aleatória porém representativa de todos os dados (sem restrição por classe).

Cenário Não-IID. A separação seguiu três etapas. **(i) Atribuição de classes por cliente:** a cada cliente são sorteadas aleatoriamente entre 1 e 3 classes (`max_classes = 3`); garante-se que toda classe possua ao menos um cliente responsável. **(ii) Alocação de amostras por classe:** para cada classe, o conjunto de clientes elegíveis recebe proporções amostradas de $\mathrm{Dir}(\mathbf{1}_{|S_c|})$, onde $|S_c|$ é o número de clientes que possuem a classe c. Os índices dos exemplares de cada classe são embaralhados antes da divisão. **(iii) Montagem dos datasets locais:** os exemplares de cada classe são copiados para os clientes conforme as proporções calculadas; ao final, cada dataset local é embaralhado novamente para evitar ordenação por classe.

2 Arquitetura da Rede Neural

O modelo global é uma CNN com dois blocos convolucionais seguidos de camadas densamente conectadas, conforme a Tabela 1. Otimizador: **Adam**. Função de perda: *sparse categorical cross-entropy*. Entrada: $32 \times 32 \times 3$.

Tabela 1: Arquitetura da CNN utilizada como modelo global.

#	Tipo	Filtros / Unidades	Detalhe
1	Conv2D	32 filtros 3×3	ReLU, *same*
2	Conv2D	32 filtros 3×3	ReLU, *same*
3	MaxPooling2D	2×2	—
4	Dropout	—	$p = 0{,}25$
5	Conv2D	64 filtros 3×3	ReLU, *same*
6	Conv2D	64 filtros 3×3	ReLU, *same*
7	MaxPooling2D	2×2	—
8	Dropout	—	$p = 0{,}25$
9	Flatten	—	—
10	Dense	512	ReLU
11	Dropout	—	$p = 0{,}50$
12	Dense (saída)	10	Softmax

3 Configuração Experimental

Tabela 2: Parâmetros utilizados nos experimentos.

Parâmetro	Síncrono	Assíncrono
Número de clientes	40	40
Rodadas / atualizações	80	80
Épocas locais por rodada	1	1
Batch size	32	32
Atraso de conexão	$\mathcal{U}(0,5)$ s	$\mathcal{U}(0,5)$ s
Atraso de treinamento	$\mathcal{U}(0,90)$ s	$\mathcal{U}(0,90)$ s
Critério de rodada (% de clientes)	25 / 50 / 75%	—
Timeout (percentil da dist. de atraso)	—	25 / 50 / 75%
Fator base α_0	—	0,8
Decaimento δ	—	0,999
Sensibilidade ρ	—	0,075
Semente aleatória	42	42

No modo **síncrono** (FedAvg), o servidor aguarda uma fração dos clientes (25%, 50% ou 75%) antes de agregar os pesos por média ponderada pelo tamanho do *dataset* local.

No modo **assíncrono**, cada atualização é incorporada imediatamente ao modelo global com fator de agregação $\gamma_t = \alpha_0 \cdot \delta^v \cdot (1 + \lambda\, s)^{-1}$, onde $s = v_{\text{servidor}} - v_{\text{cliente}}$ é a *staleness*.

Simulação de latência e definição dos critérios de parada. Cada cliente simula um atraso total $\Delta t = \Delta t_{\text{conn}} + \Delta t_{\text{train}}$, com $\Delta t_{\text{conn}} \sim \mathcal{U}(0, 5)$ s e $\Delta t_{\text{train}} \sim \mathcal{U}(0, 90)$ s, representando, respectivamente, o tempo de conexão e o tempo de treinamento local.

No modo **assíncrono**, o timeout global precisa ser expresso em segundos. Para isso, amostrou-se 10^6 realizações de Δt (simulação de Monte Carlo) e calcularam-se os percentis $p \in \{25, 50, 75\}$ da distribuição empírica resultante, obtendo os valores P_p em segundos. O timeout de cada configuração é então $T_p = P_p \times N_{\text{upd}}$, onde $N_{\text{upd}} = 80$, de modo que o limite de tempo escala proporcionalmente ao número total de atualizações esperadas.

No modo **síncrono**, não há timeout em segundos: o encerramento de cada rodada é definido diretamente pela fração de clientes que responderam. Os mesmos valores $p \in \{25, 50, 75\}$ são usados como percentuais de participação mínima — a rodada termina assim que $p\%$ dos clientes entregarem seus pesos, descartando os demais.

4 Resultados — Síncrono

Geração dos gráficos. As curvas suavizadas utilizam **Média Móvel Exponencial** (EMA) com fator $\alpha = 0{,}1$, definida pela recorrência $s_t = \alpha\, x_t + (1 - \alpha)\, s_{t-1}$. As bandas de confiança exibidas nos subplots individuais são calculadas suavizando pela mesma EMA o desvio absoluto entre os dados originais e a curva suavizada, produzindo bandas simétricas e contínuas. Os *boxplots* dividem a série em faixas uniformes e exibem a distribuição bruta (sem suavização) da acurácia em cada faixa.

IID

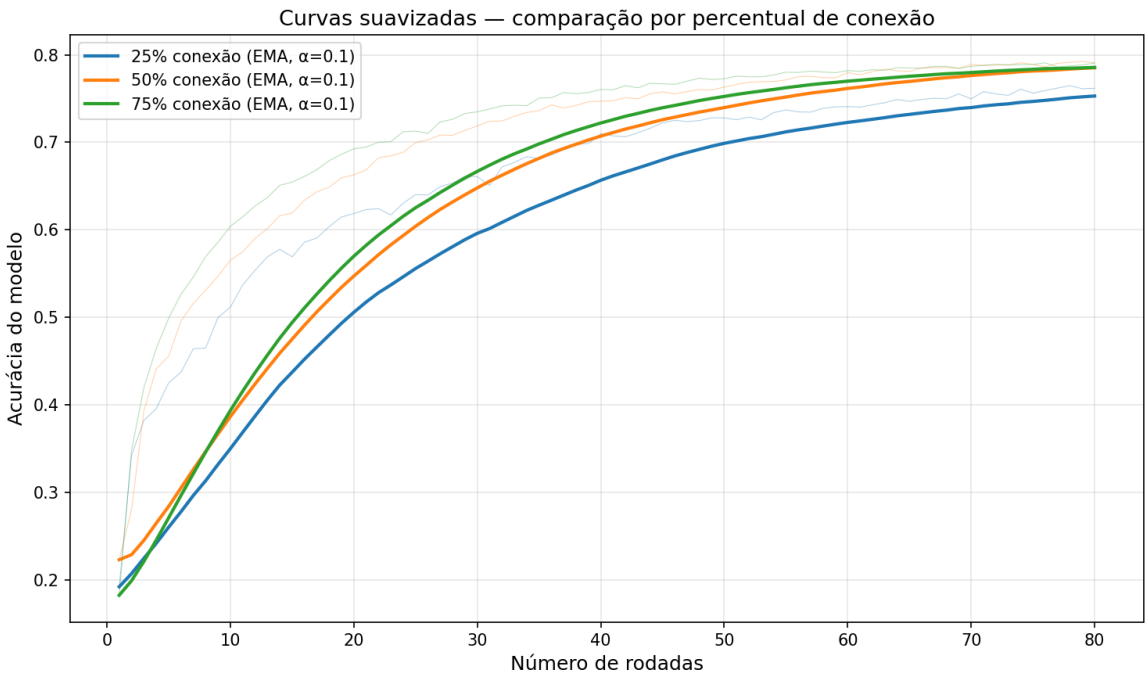

Figura 1: Síncrono / IID — curvas de acurácia suavizadas por EMA ($\alpha = 0{,}1$), comparadas por percentual mínimo de conexão.

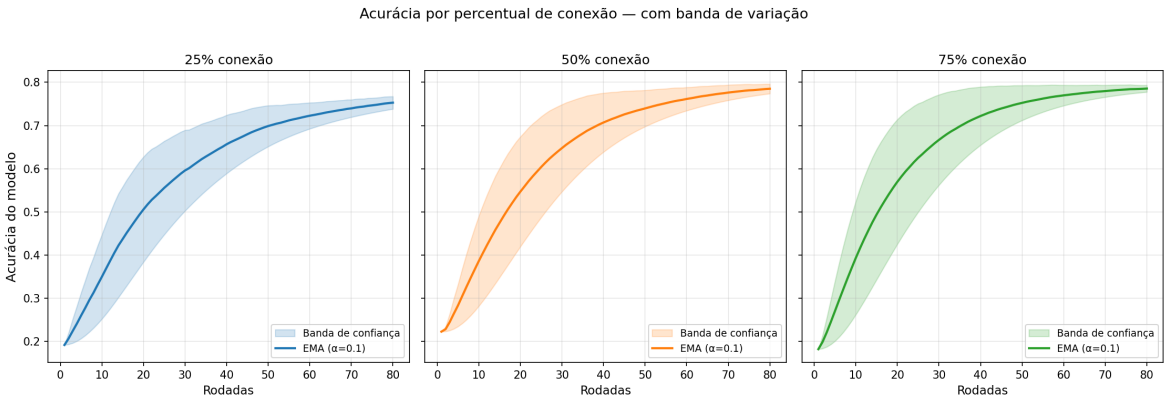

Figura 2: Síncrono / IID — banda de confiança baseada no desvio absoluto suavizado por EMA ($\alpha = 0{,}1$).

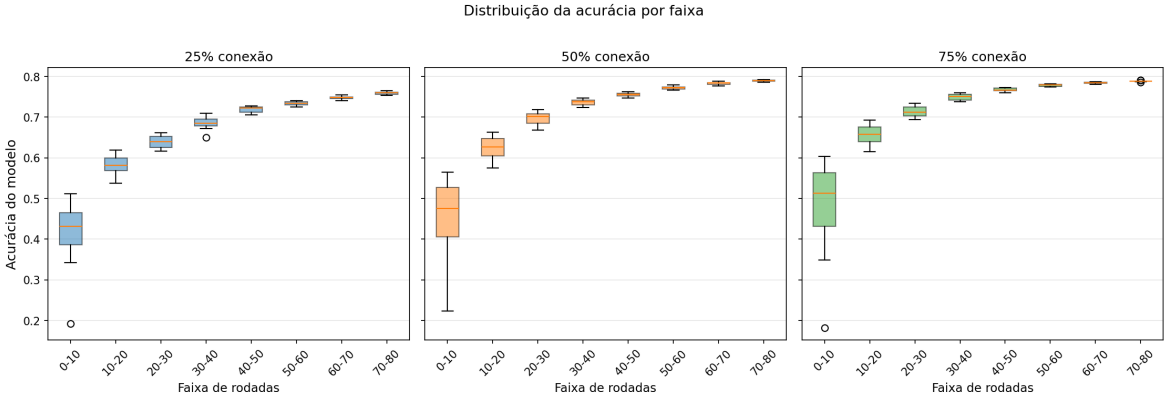

Figura 3: Síncrono / IID — *boxplot* por faixas de rodadas.

Não-IID

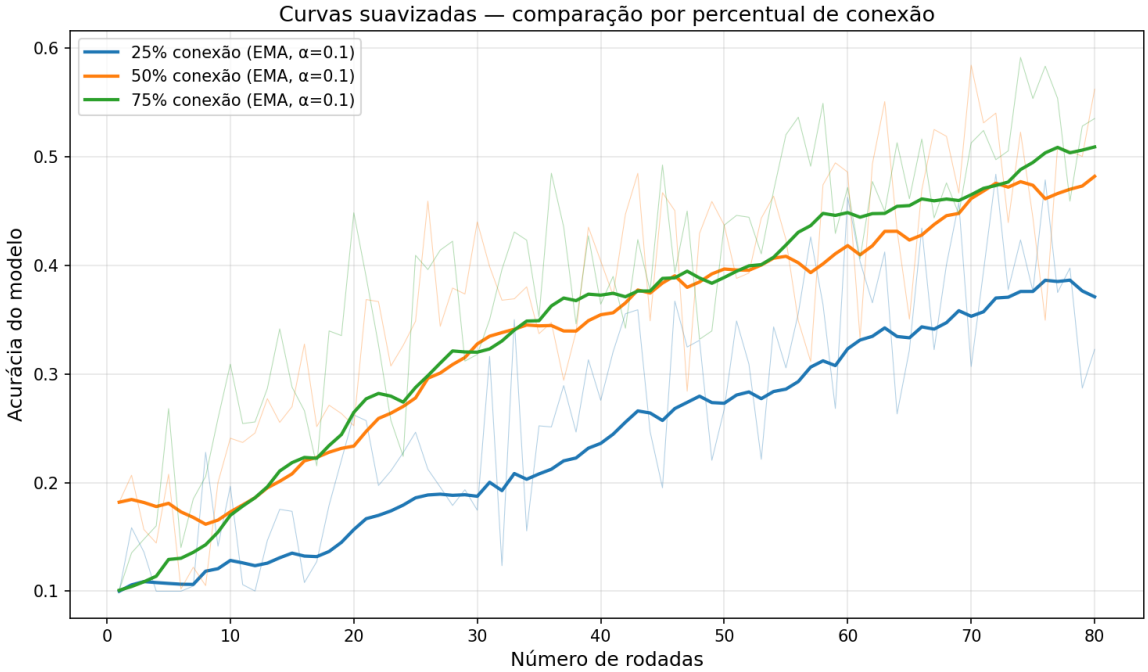

Figura 4: Síncrono / Não-IID — curvas de acurácia suavizadas por EMA ($\alpha = 0{,}1$), comparadas por percentual mínimo de conexão.

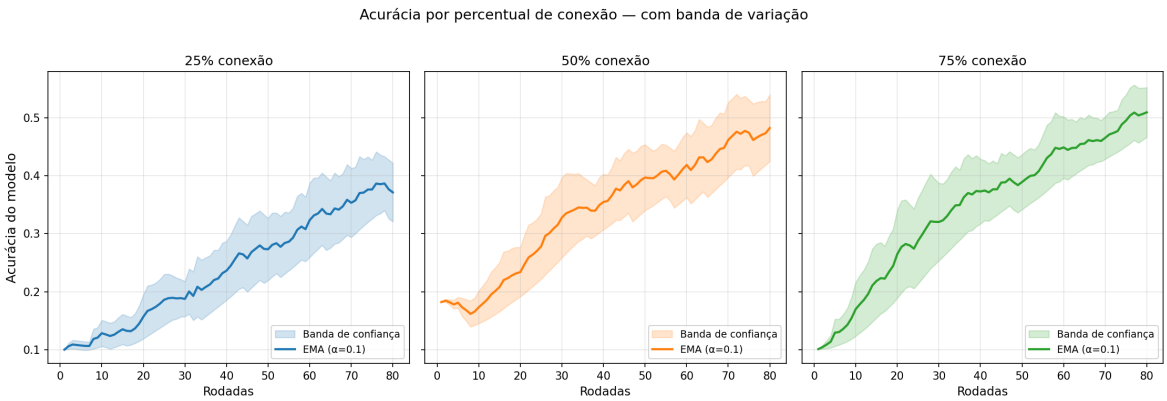

Figura 5: Síncrono / Não-IID — banda de confiança baseada no desvio absoluto suavizado por EMA ($\alpha = 0{,}1$).

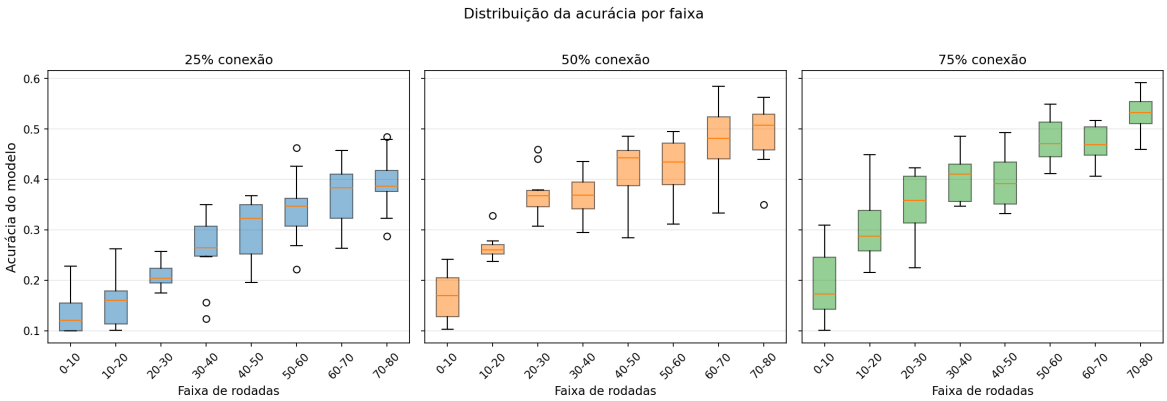

Figura 6: Síncrono / Não-IID — *boxplot* por faixas de rodadas.

5 Resultados — Assíncrono

IID

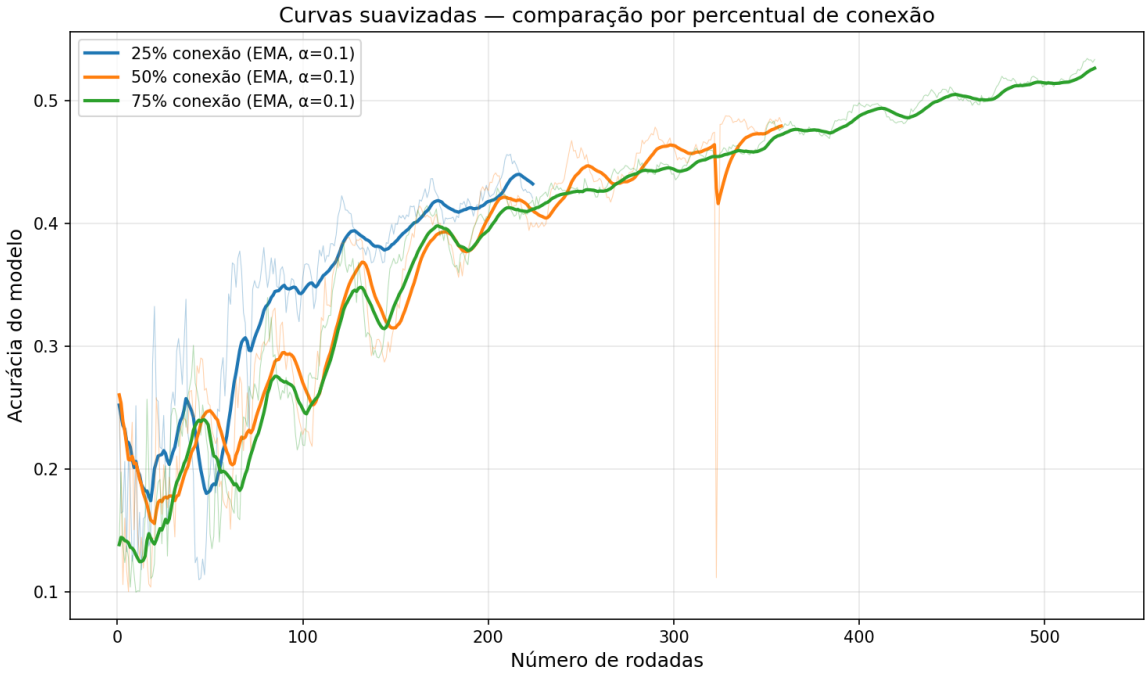

Figura 7: Assíncrono / IID — curvas de acurácia suavizadas por EMA ($\alpha = 0{,}1$), comparadas por *timeout*.

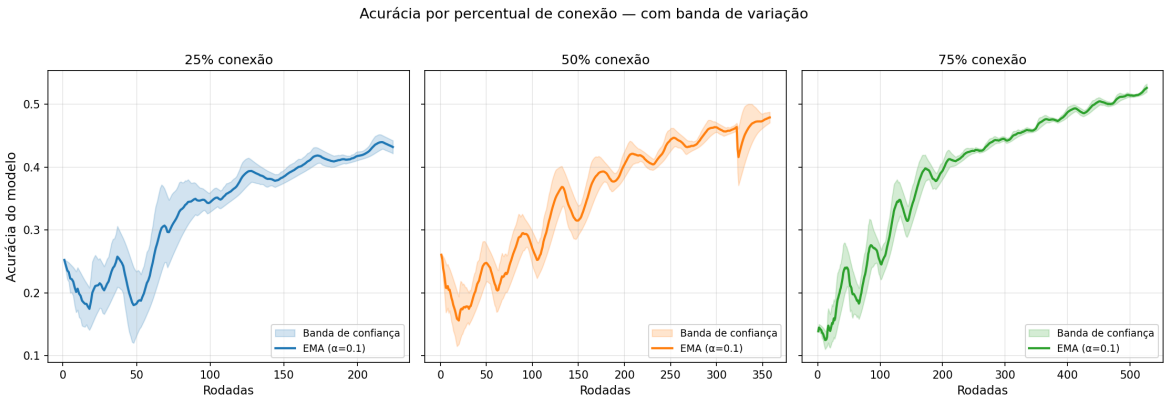

Figura 8: Assíncrono / IID — banda de confiança baseada no desvio absoluto suavizado por EMA ($\alpha = 0{,}1$).

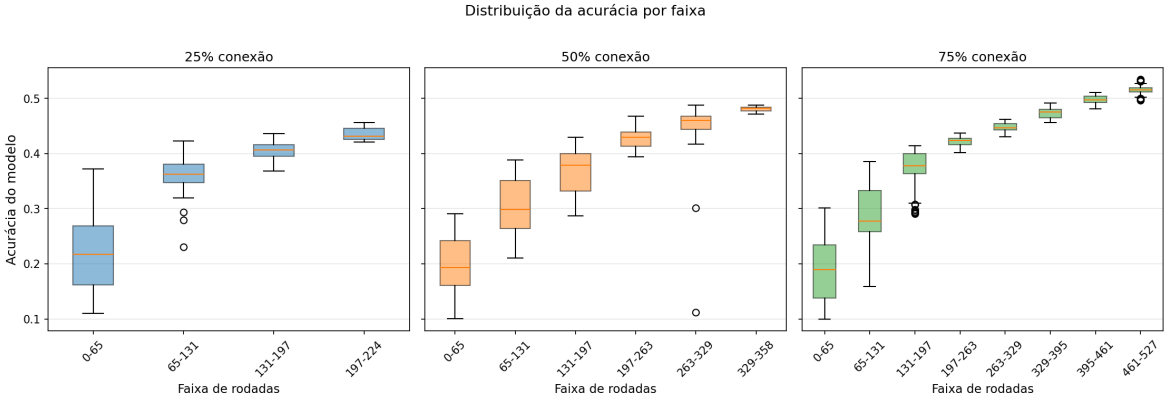

Figura 9: Assíncrono / IID — *boxplot* por faixas de atualizações.

Não-IID

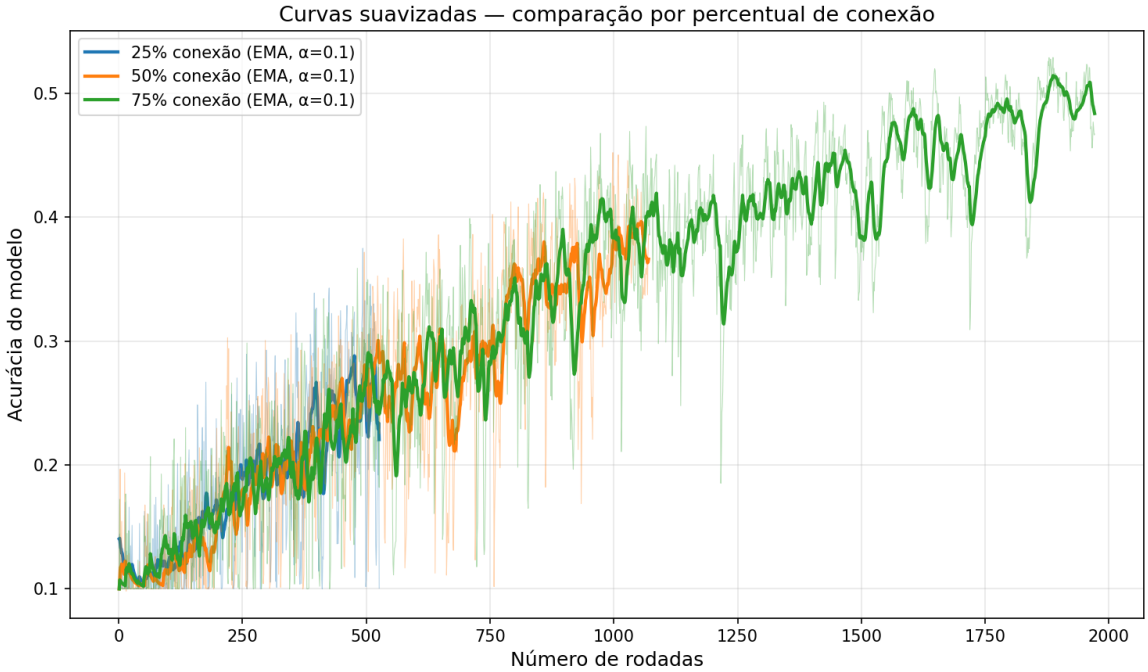

Figura 10: Assíncrono / Não-IID — curvas de acurácia suavizadas por EMA ($\alpha = 0{,}1$), comparadas por *timeout*.

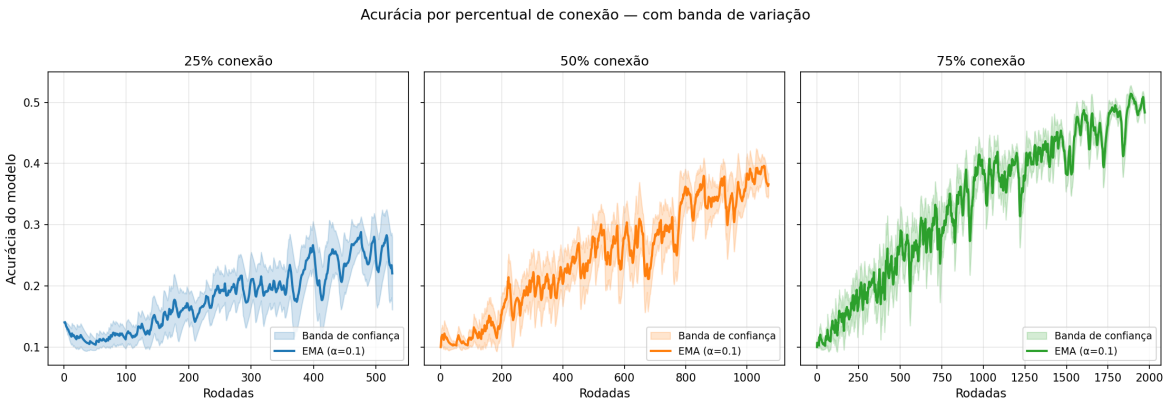

Figura 11: Assíncrono / Não-IID — banda de confiança baseada no desvio absoluto suavizado por EMA ($\alpha = 0{,}1$).

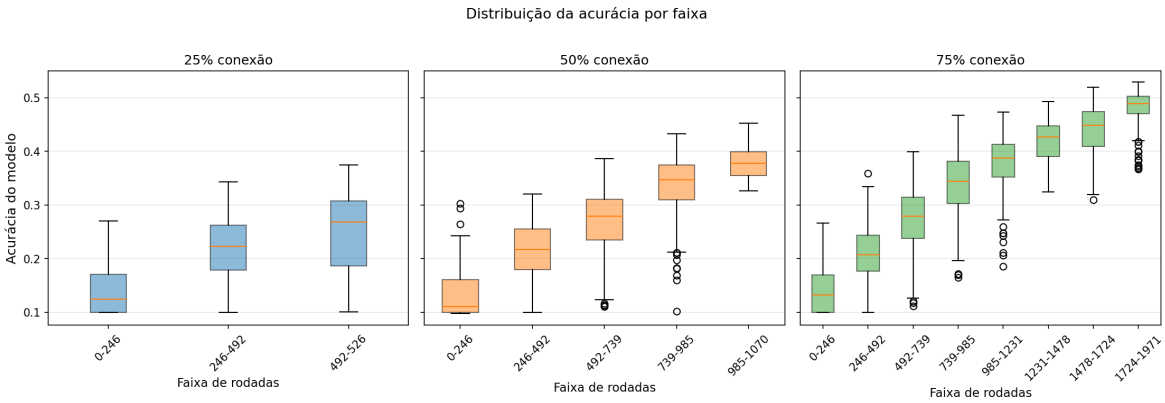

Figura 12: Assíncrono / Não-IID — *boxplot* por faixas de atualizações.