Simulação de Aprendizado Federado: Novos Experimentos

Júlio

30 de março de 2026

Este relatório apresenta os resultados dos três estudos conduzidos após a entrega inicial: (i) estudo de ablação do fator de agregação assíncrono (CIFAR-10); (ii) generalização para múltiplos datasets; e (iii) análise do impacto do *timeout* no cenário síncrono (CIFAR-10).

1 Datasets Utilizados

Os experimentos de generalização avaliaram quatro datasets com complexidades distintas, conforme a Tabela 1.

Tabela 1: Datasets avaliados nos experimentos de generalização.

Dataset	**Tarefa**	**Classes**	**Complexidade**
MNIST	Dígitos manuscritos	10	Baixa
Fashion MNIST	Peças de roupa	10	Média-baixa
CIFAR-10	Objetos naturais (RGB)	10	Média-alta
GTSRB	Placas de trânsito (RGB)	43	Alta

A distribuição dos dados entre clientes foi avaliada em dois cenários — **IID** e **Não-IID** — conforme descrito no relatório anterior.

2 Configuração Experimental

Tabela 2: Parâmetros utilizados nos experimentos.

Parâmetro	**Ablação / Generalização**	**Impacto do Timeout**
Modo	Assíncrono	Síncrono
Dataset	CIFAR-10 / múltiplos	CIFAR-10
Número de clientes	40	40
Rodadas / atualizações	40 / 80	80
Épocas locais por rodada	1	1
Batch size	32	32
Atraso de conexão	$\mathcal{U}(0,5)$ s	$\mathcal{U}(0,5)$ s
Atraso de treinamento	$\mathcal{U}(0,90)$ s	$\mathcal{U}(0,90)$ s
Probabilidade de conexão	$p50$	—
Fator base α_0	0,3 / 0,5 / 0,8 (ablação)	—
Decaimento δ	0,95 / 0,99 / 0,999 (ablação)	—
Sensibilidade ρ	0 / 0,075 / 0,5 (ablação)	—
Timeout (percentil via Monte Carlo)	—	P25 / P50 / P75 / Sem
Semente aleatória	42	42

Para o estudo de impacto do *timeout*, os valores foram derivados via simulação de Monte Carlo (10^6 realizações de $\Delta t = \Delta t_{\text{conn}} + \Delta t_{\text{train}}$), obtendo os percentis $P_{25} = 24{,}99$ s, $P_{50} = 47{,}45$ s, $P_{75} = 69{,}95$ s e o limite máximo de 95,00 s (sem timeout).

3 Estudo de Ablação — FL Assíncrono (CIFAR-10)

Foram conduzidos 14 experimentos *one-at-a-time*, variando isoladamente cada parâmetro do fator de agregação $\gamma_t = \alpha_0 \cdot \delta^v \cdot (1 + \rho\, s)^{-1}$. As demais variáveis foram mantidas fixas nos valores padrão: $\alpha_0 = 0{,}8$, $\delta = 0{,}999$, $\rho = 0{,}075$.

3.1 Impacto do Fator Base α_0

Tabela 3: Impacto de α_0 na acurácia. Fixos: $\delta = 0{,}999$, $\rho = 0{,}075$.

α_0	IID máx.	IID avg_last10	Non-IID máx.	Non-IID avg_last10	Non-IID tail_std
0,3	0,6578	0,6569	**0,4609**	**0,4350**	0,0329
0,5	0,6785	0,6771	0,4581	0,3857	0,0435
0,8	**0,6812**	**0,6800**	0,4604	0,3760	**0,0588**

Em IID, o impacto de α_0 é pequeno ($\approx 2\%$). Em Non-IID, $\alpha_0 = 0{,}8$ apresenta o dobro do desvio-padrão de $\alpha_0 = 0{,}3$ na cauda (0,059 vs 0,033): valores altos amplificam as

oscilações causadas por updates heterogêneos.

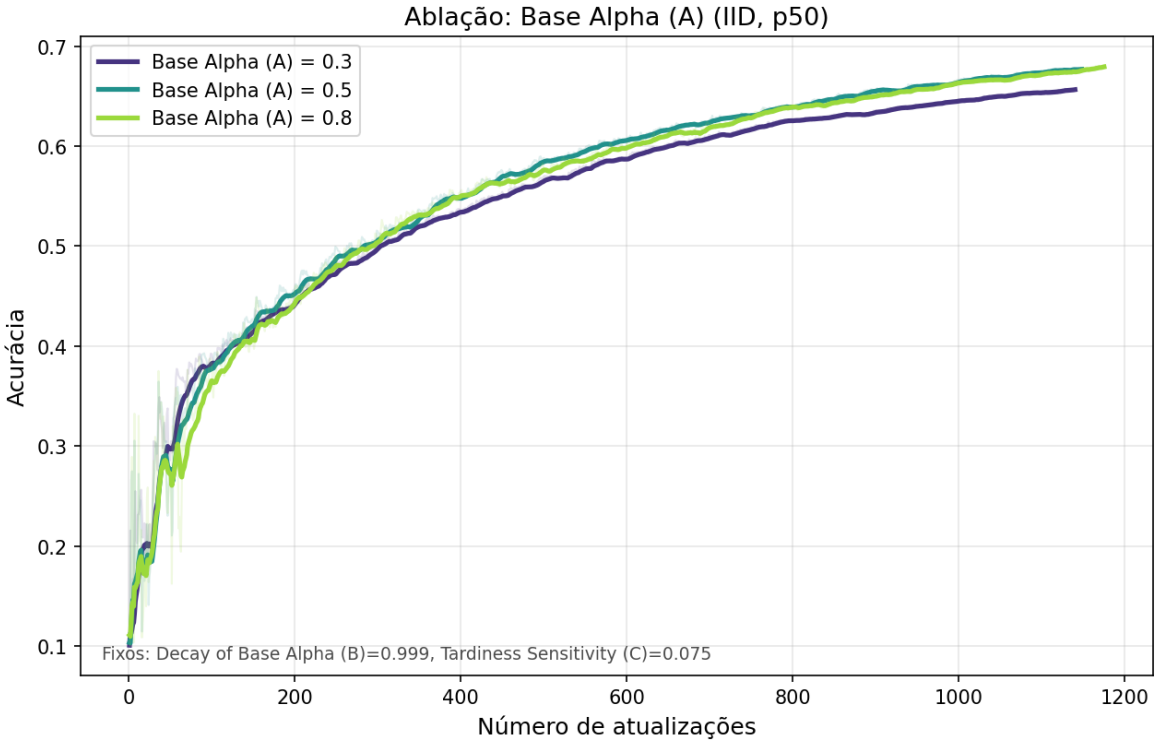

Figura 1: Ablação de α_0 — cenário IID.

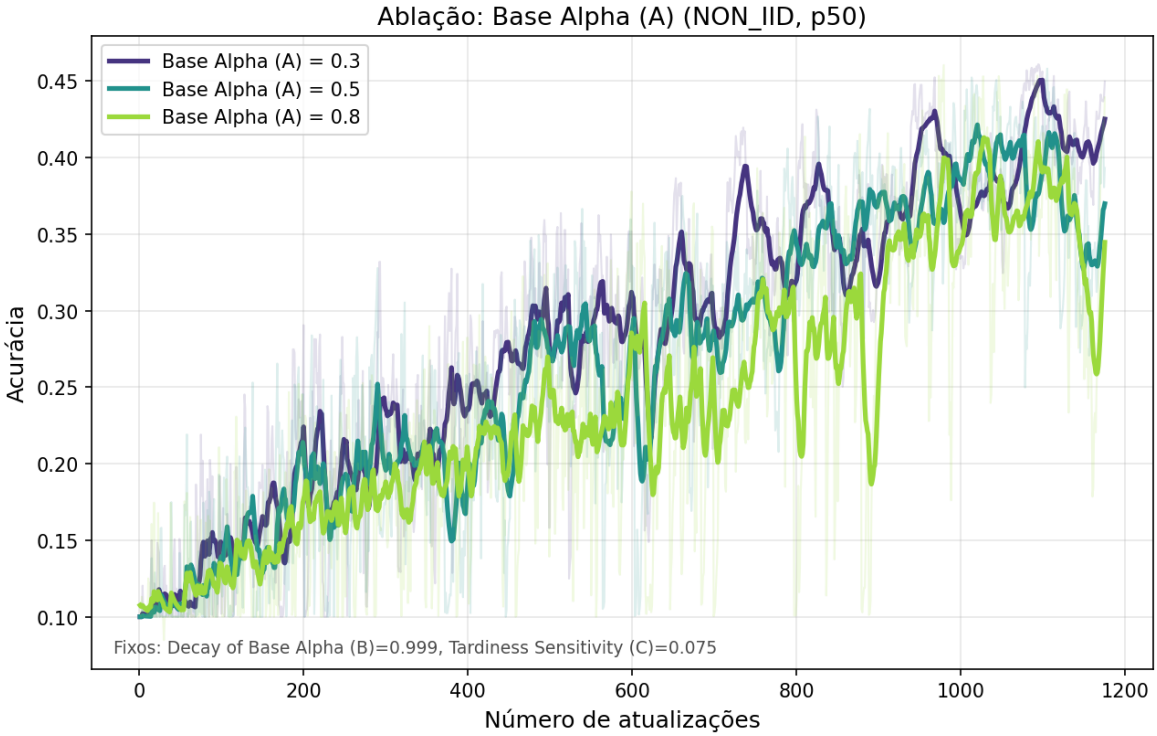

Figura 2: Ablação de α_0 — cenário Não-IID.

3.2 Impacto do Decaimento δ

Tabela 4: Impacto de δ na acurácia. Fixos: $\alpha_0 = 0{,}8$, $\rho = 0{,}075$.

δ	IID máx.	IID avg_last10	Non-IID máx.	Non-IID avg_last10
0,999	**0,6812**	**0,6800**	**0,4604**	**0,3760**
0,99	0,4982	0,4970	0,3685	0,3521
0,95	0,3180	0,3180	0,1684	0,1000

δ é o parâmetro mais crítico da fórmula. $\delta = 0{,}95$ causa estagnação em $\approx 32\%$ (IID) e colapso para acurácia aleatória (Non-IID). Após 100 atualizações: $0{,}95^{100} \approx 0{,}006$ vs. $0{,}999^{100} \approx 0{,}905$ — o orçamento de aprendizado se esgota cedo demais com decaimento agressivo.

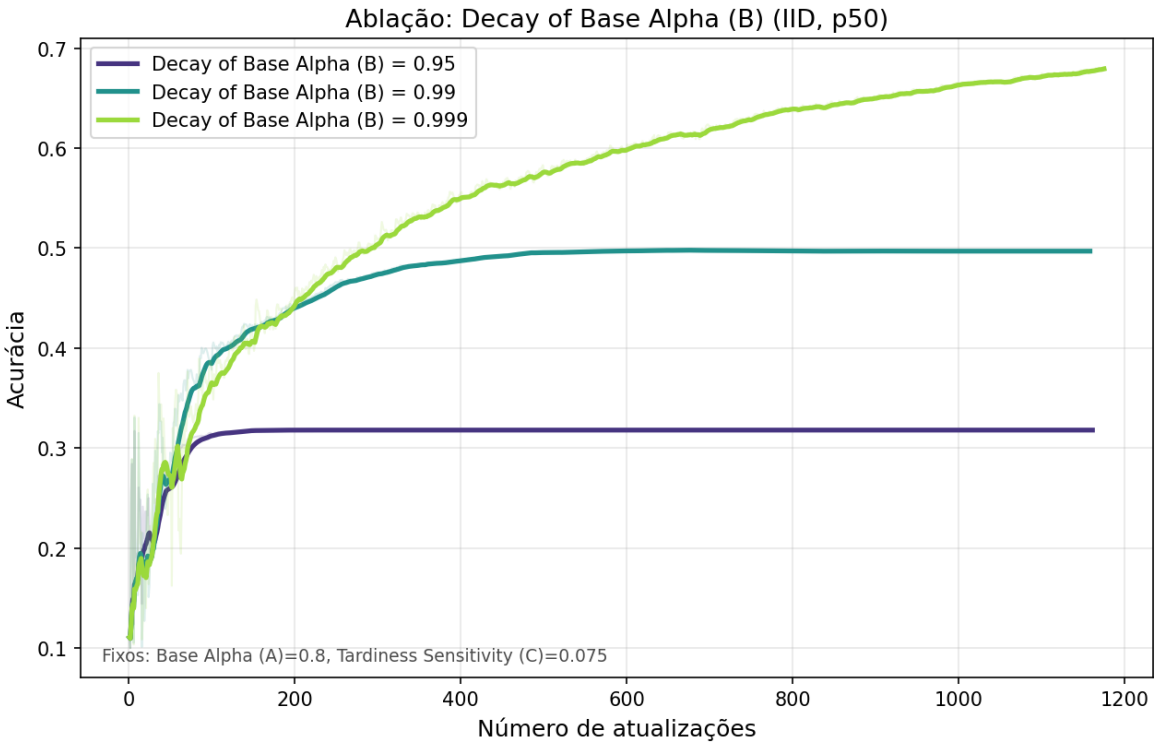

Figura 3: Ablação de δ — cenário IID.

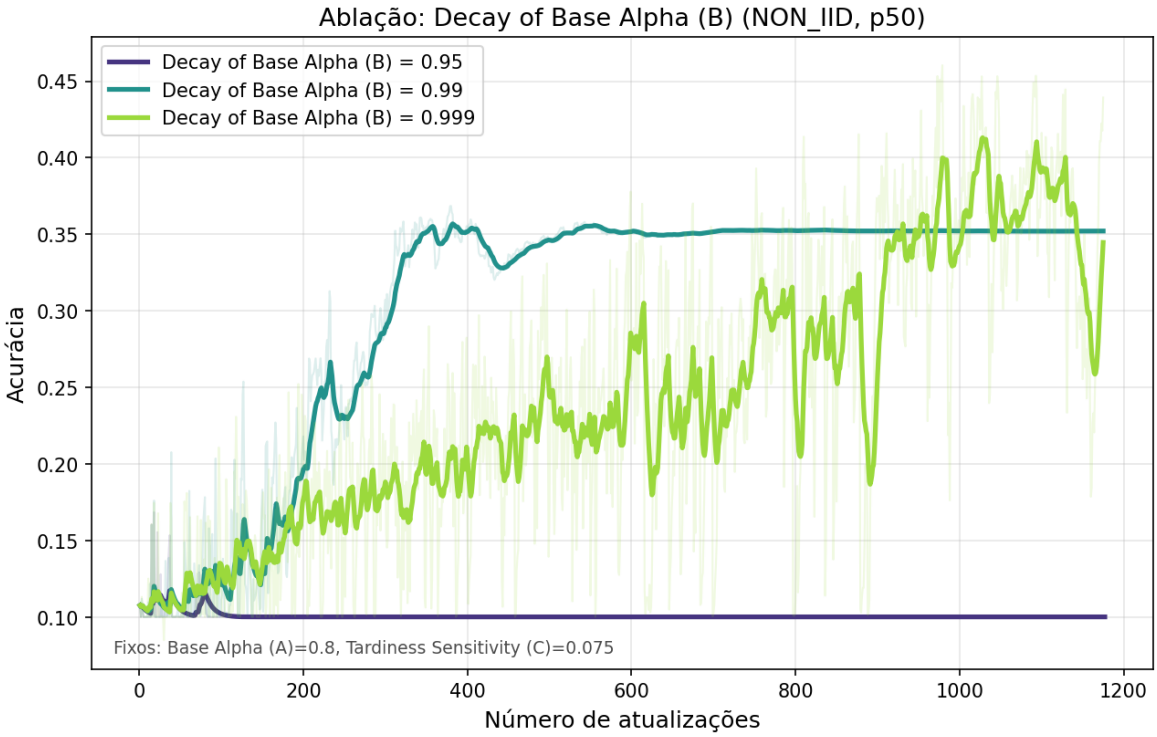

Figura 4: Ablação de δ — cenário Não-IID.

3.3 Impacto da Sensibilidade ao *Staleness* ρ

Tabela 5: Impacto de ρ na acurácia. Fixos: $\alpha_0 = 0{,}8$, $\delta = 0{,}999$.

ρ	IID máx.	IID avg_last10	IID tail_std	Non-IID máx.	Non-IID avg_last10
0,000	0,6788	0,6761	0,0098	0,2689	0,1600
0,075	**0,6812**	**0,6800**	0,0066	**0,4604**	0,3760
0,500	0,6404	0,6394	0,0060	0,4547	**0,4379**

Sem penalização ($\rho = 0$), o modelo colapsa para $\approx 16\%$ em Non-IID — **falha total**. A penalização por *staleness* é estruturalmente necessária para que a agregação assíncrona funcione em cenários heterogêneos: updates defasados de clientes com distribuições enviesadas corrompem o modelo global quando incorporados com peso integral. $\rho = 0{,}5$ oferece maior estabilidade (avg_last10 $= 0{,}44$) ao custo de ligeira redução na velocidade de convergência.

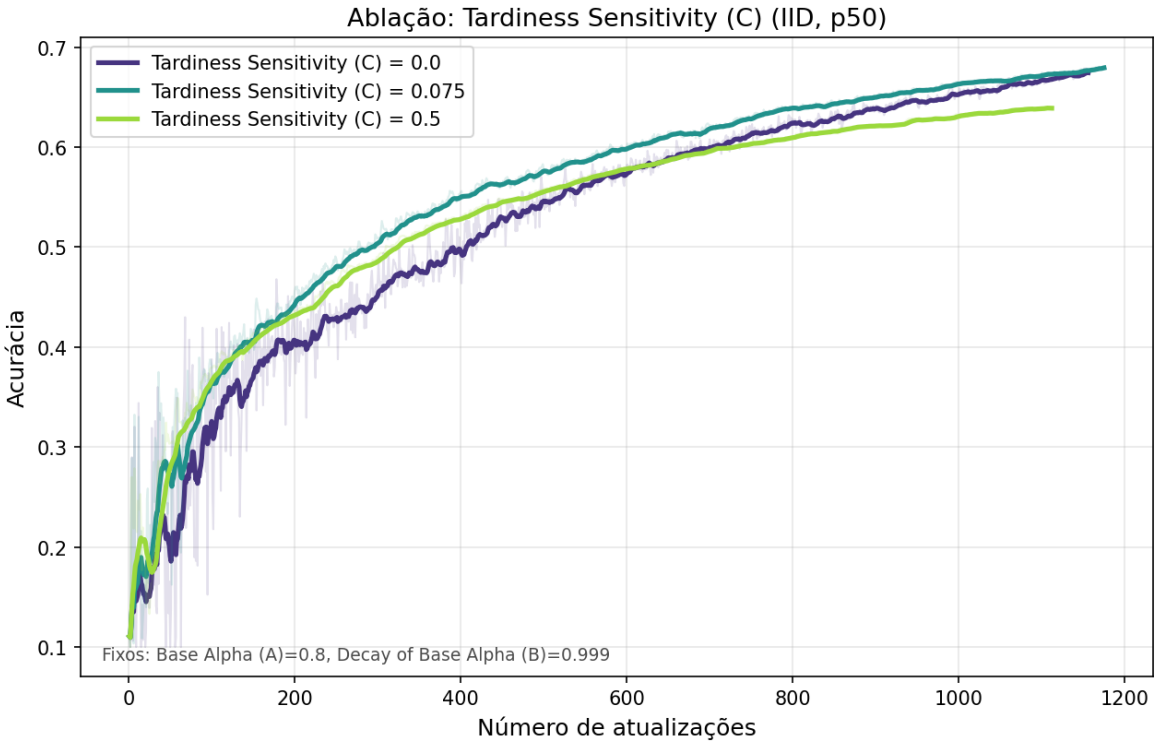

Figura 5: Ablação de ρ — cenário IID.

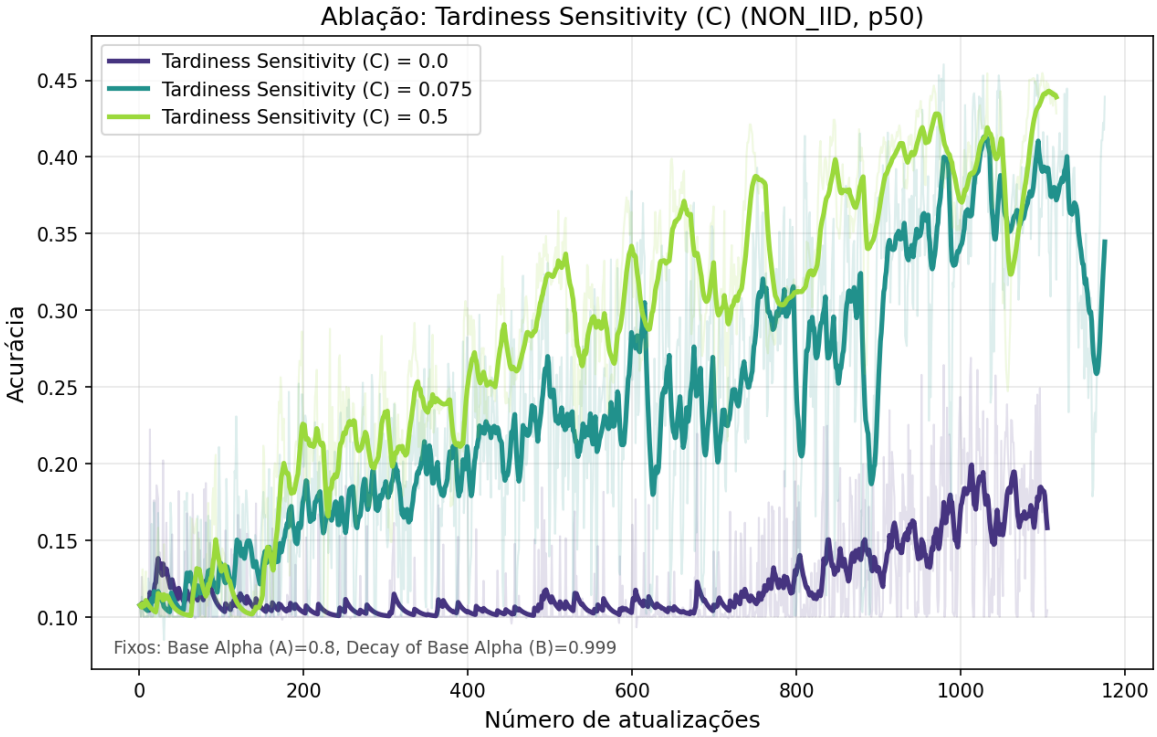

Figura 6: Ablação de ρ — cenário Não-IID.

3.4 Conclusões da Ablação

1. δ **é o parâmetro mais sensível**: valores abaixo de 0,999 causam degradação significativa; $\delta = 0{,}95$ é catastrófico em ambos os cenários. Recomendação: $\delta \geq 0{,}999$.
2. ρ **é dispensável em IID, mas indispensável em Non-IID**: sem penalização por *staleness*, o sistema simplesmente não funciona em cenários heterogêneos — este resultado sugere que ρ é um pré-requisito funcional, não um refinamento cosmético.
3. α_0 **apresenta trade-off estabilidade vs. velocidade**: em Non-IID, $\alpha_0 = 0{,}3$ converge mais devagar, mas com metade das oscilações de $\alpha_0 = 0{,}8$.
4. **A fórmula tripartite é validada**: os três componentes têm papéis complementares e não redundantes.
5. **Non-IID amplifica todas as sensibilidades**: parâmetros que funcionam em IID podem colapsar em Non-IID.

4 Generalização para Múltiplos Datasets — FL Assíncrono

Os parâmetros identificados na ablação ($\alpha_0 = 0{,}8$, $\delta = 0{,}999$, $\rho = 0{,}075$) foram aplicados sem ajuste fino a quatro datasets distintos, por $\approx$ 1h33min cada.

4.1 Cenário IID

Tabela 6: Resultados no cenário IID para os quatro datasets.

Dataset	Aval.	Acurácia Máx.	Média Last10	Tail Std	Conv. @90%	Loss Final
MNIST	4731	0,9938	0,9937	0,0004	3/4731	0,0191
Fashion MNIST	3809	0,9185	0,9181	0,0030	348/3809	0,2223
CIFAR-10	4645	0,7362	0,7349	0,0108	2715/4645	0,7573
GTSRB	2534	0,9625	0,9613	0,0023	813/2534	0,1531

4.2 Cenário Não-IID

Tabela 7: Resultados no cenário Não-IID para os quatro datasets.

Dataset	Aval.	Acurácia Máx.	Média Last10	Tail Std	Conv. @90%	Loss Final
MNIST	4828	0,9859	0,9837	0,0033	953/4828	0,0546
Fashion MNIST	3860	0,8472	0,8369	0,0278	1554/3860	0,4945
CIFAR-10	5253	0,4765	0,4465	0,0391	4002/5253	1,4638
GTSRB	2633	0,4899	0,2374	0,0759	2466/2633	2,6594

4.3 Impacto IID → Não-IID por Dataset

Tabela 8: Degradação de desempenho ao passar de IID para Não-IID.

Dataset	**Δ Acurácia Máx.**	**Δ Avg Last10**	**Razão Tail Std (non/iid)**
MNIST	−0,0079	−0,0100	8,1×
Fashion MNIST	−0,0713	−0,0812	9,3×
CIFAR-10	−0,2597	−0,2884	3,6×
GTSRB	−0,4726	−0,7239	33,3×

O GTSRB é o dataset mais sensível à heterogeneidade: queda de 47,26 p.p. e instabilidade 33,3× maior em Não-IID. Com 43 classes e dados de trânsito naturalmente desbalanceados por região, reforça a importância de ρ adaptativo em datasets multiclasse com alta heterogeneidade natural.

O comportamento observado no CIFAR-10 generaliza para todos os datasets: convergência consistente em IID, queda de acurácia e maior instabilidade em Não-IID são padrões universais, e não artefatos do CIFAR-10.

5 Impacto do *Timeout* — FL Síncrono (CIFAR-10)

O servidor aguarda os clientes por no máximo T_p segundos por rodada, onde T_p é o percentil p da distribuição empírica de Δt (via Monte Carlo), conforme a Tabela 9.

Tabela 9: *Timeouts* derivados via simulação de Monte Carlo (10^6 realizações).

Configuração	**Timeout (s)**	**Clientes descartados por rodada**
P25	24,99 s	75% dos clientes lentos
P50	47,45 s	50% dos clientes lentos
P75	69,95 s	25% dos clientes lentos
Sem timeout	95,00 s	Nenhum

Geração dos gráficos. As curvas suavizadas utilizam EMA com fator $\alpha = 0{,}1$. As bandas de confiança são calculadas suavizando pela mesma EMA o desvio absoluto entre os dados originais e a curva suavizada. Os *boxplots* exibem a distribuição bruta por faixas de rodadas.

5.1 Cenário IID

Tabela 10: Acurácia final e máxima — IID.

Configuração	Acurácia R80	Acurácia Máx.	Loss Final
P25	73,7%	73,8%	0,7526
P50	76,6%	76,7%	0,6777
P75	77,7%	78,1%	0,6511
Sem timeout	**79,1%**	**79,2%**	**0,6311**

Tabela 11: Tempo de execução e eficiência por hora — IID.

Configuração	Tempo/rodada	Tempo total	Ganho vs. sem timeout	Acurácia/hora
P25	28,2 s	37,7 min	−70,4%	117,3%/h
P50	50,7 s	67,6 min	−48,8%	68,0%/h
P75	73,8 s	98,5 min	−25,4%	47,3%/h
Sem timeout	99,0 s	132,0 min	—	35,9%/h

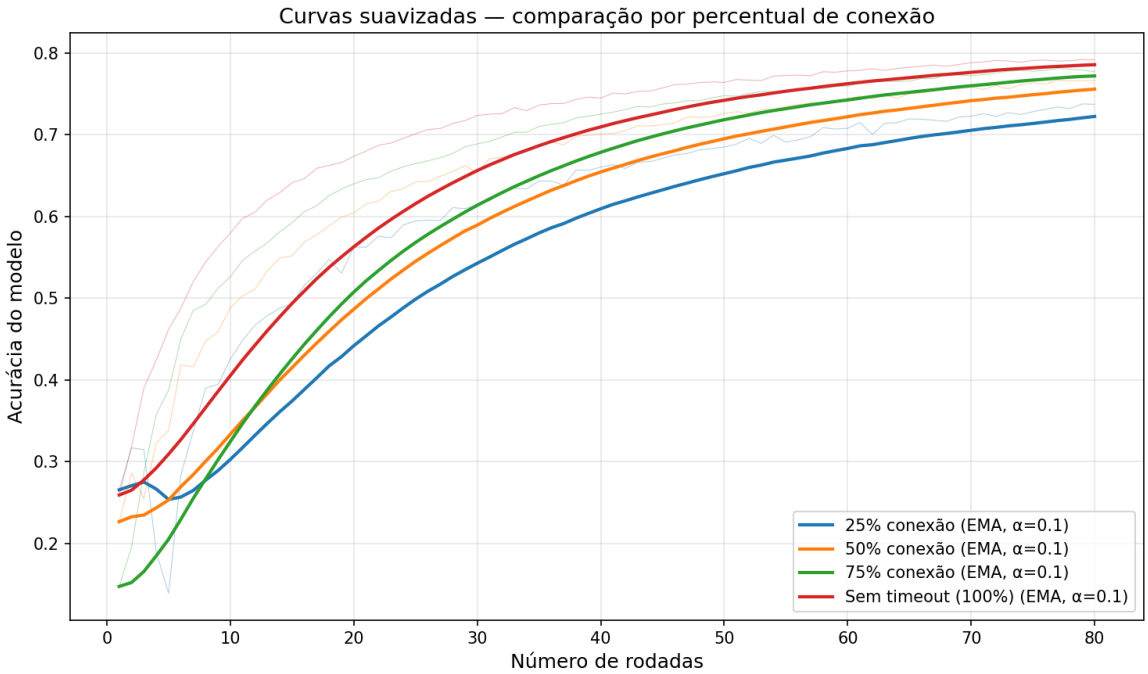

Figura 7: Síncrono / IID — curvas de acurácia suavizadas por EMA ($\alpha = 0{,}1$), comparadas por configuração de *timeout*.

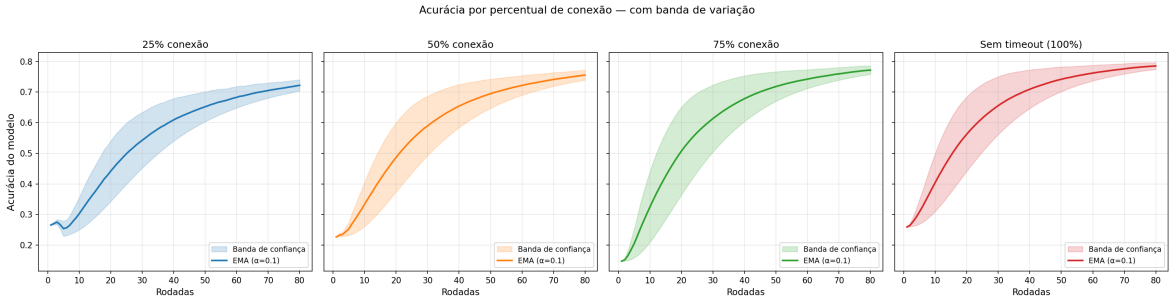

Figura 8: Síncrono / IID — banda de confiança baseada no desvio absoluto suavizado por EMA ($\alpha = 0{,}1$).

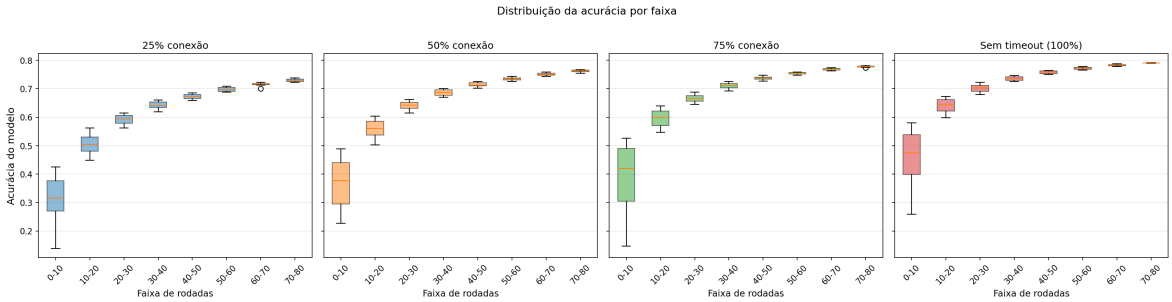

Figura 9: Síncrono / IID — *boxplot* por faixas de rodadas.

5.2 Cenário Não-IID

Tabela 12: Acurácia final e máxima — Não-IID.

Configuração	Acurácia R80	Acurácia Máx.	Loss Final
P25	38,5%	38,5%	1,8796
P50	40,4%	49,5%	1,6215
P75	41,5%	52,5%	1,5789
Sem timeout	**50,6%**	**51,4%**	**1,3255**

Tabela 13: Estabilidade nas últimas 10 rodadas — Não-IID.

Configuração	Desvio Padrão	Mín.	Máx.
P25	0,0559	20,7%	38,5%
P50	0,0640	27,9%	49,5%
P75	0,0644	32,0%	52,5%
Sem timeout	**0,0374**	**40,4%**	**51,4%**

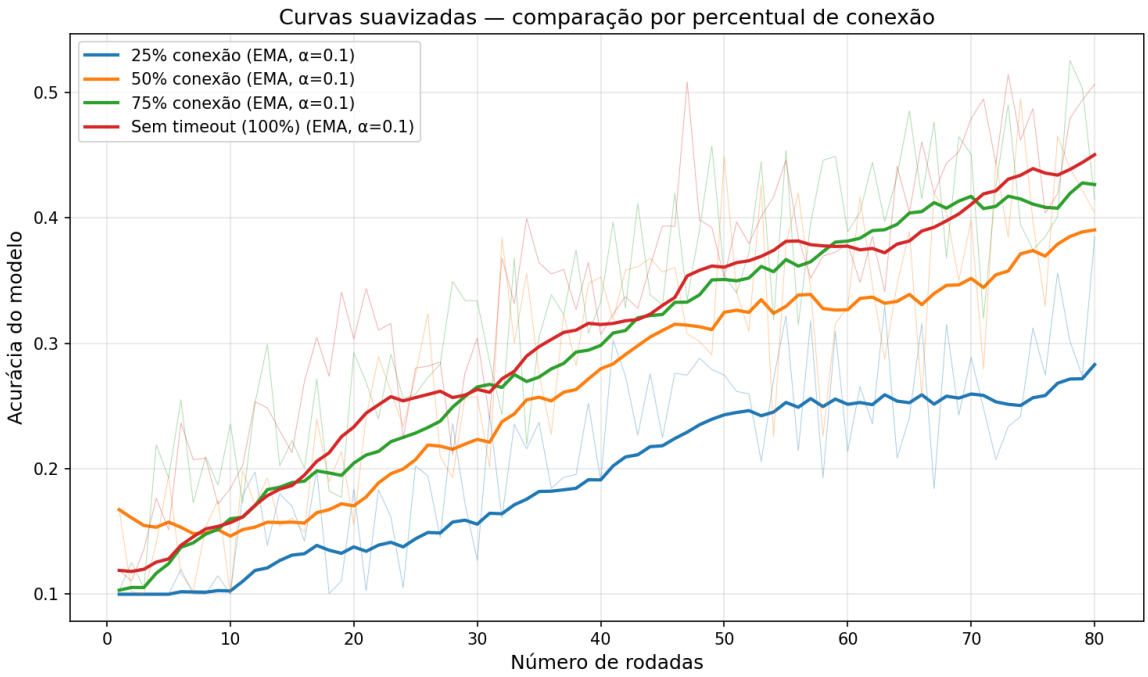

Figura 10: Síncrono / Não-IID — curvas de acurácia suavizadas por EMA ($\alpha = 0{,}1$), comparadas por configuração de *timeout*.

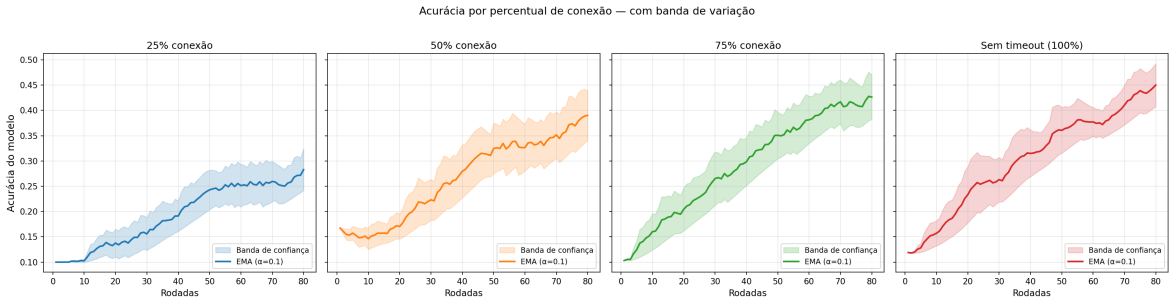

Figura 11: Síncrono / Não-IID — banda de confiança baseada no desvio absoluto suavizado por EMA ($\alpha = 0{,}1$).

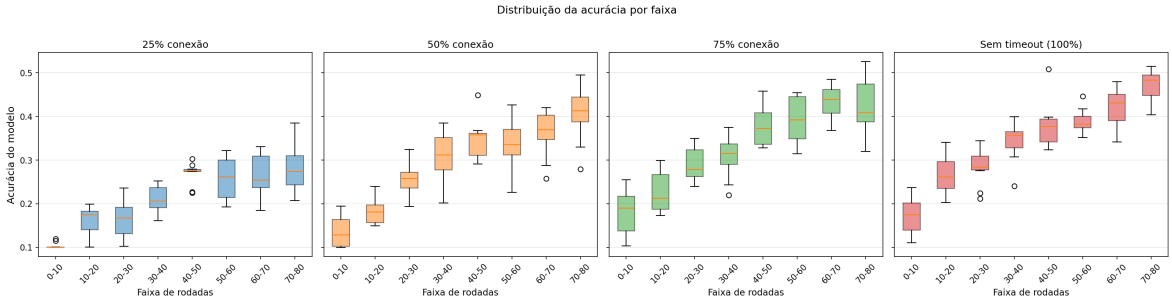

Figura 12: Síncrono / Não-IID — *boxplot* por faixas de rodadas.

5.3 Conclusões

1. **O *timeout* tem impacto significativo e mensurável** em acurácia e tempo de treinamento no cenário síncrono com CIFAR-10.
2. **Em IID**, o impacto é moderado: mesmo o timeout mais agressivo (P25) converge para 73,7%, uma redução de 5,4 p.p. em relação ao sem-timeout, mas com 3,5× menos tempo total. Em termos de acurácia por hora, P25 (117,3%/h) supera amplamente o sem-timeout (35,9%/h).
3. **Em Não-IID**, o impacto é grave: P25 nunca atinge 40% de acurácia, e o sem-timeout é o único que ultrapassa 50%. A diferença de 12,1 p.p. entre P25 e sem-timeout (vs. 5,4 p.p. no IID) indica que excluir clientes lentos prejudica a generalização em cenários heterogêneos, pois esses clientes tendem a possuir dados sub-representados.
4. **Para cenários dinâmicos** (e.g., dispositivos móveis), o timeout deve ser escolhido com cuidado. Um timeout muito curto pode excluir sistematicamente clientes com dados raros, amplificando o dano em Non-IID.
5. **A simulação de Monte Carlo** para calibrar o timeout via percentis da distribuição de latência mostrou-se uma abordagem controlada e principiada para explorar esse espaço de parâmetros.